Universidade Estadual de Santa Cruz
Oficina, continuação da palestra de 06/11 · Apoio FIAP · material em github.com/rafsp

Da Web ao Databricks

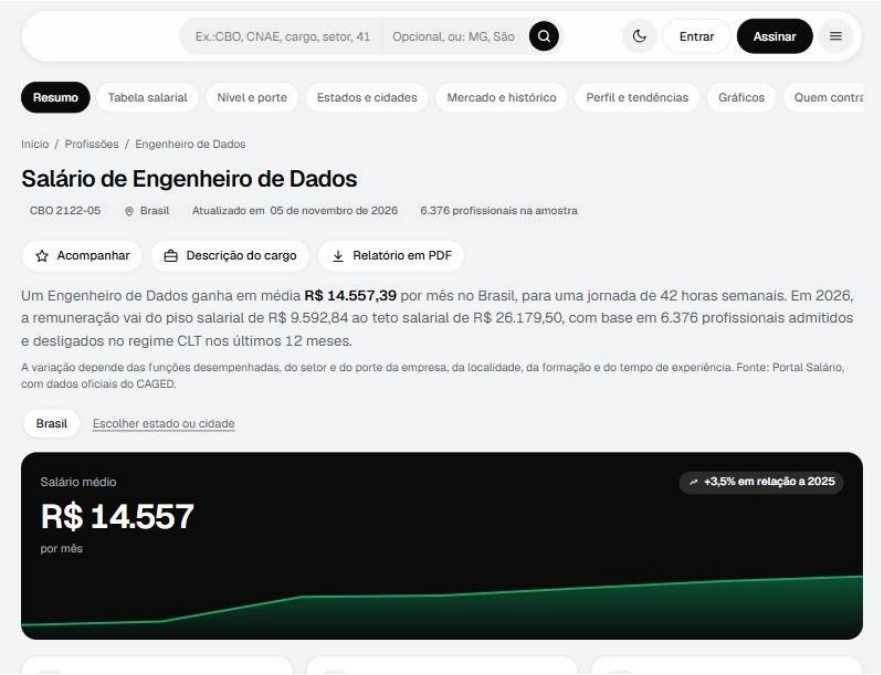
A jornada completa: web scraping, robots.txt, Azure Blob, tabela Delta, SQL e Genie, com os aluguéis de Ilhéus e Itabuna

Rafael Santos Novo Pereira
Estatística e IA na Prática · UESC, LEC · Sábado, 07/11/2026



Baía do Pontal, Ilhéus. Foto: Leandro M800, CC0, Wikimedia Commons.

O que o mercado paga a quem sabe mover dados



Portal Salário (dados do CAGED), página 'Engenheiro de Dados, CBO 2122-05', atualizada em 05/11/2026. Captura de 07/11/2026.

Engenheiro de dados, Brasil, CLT

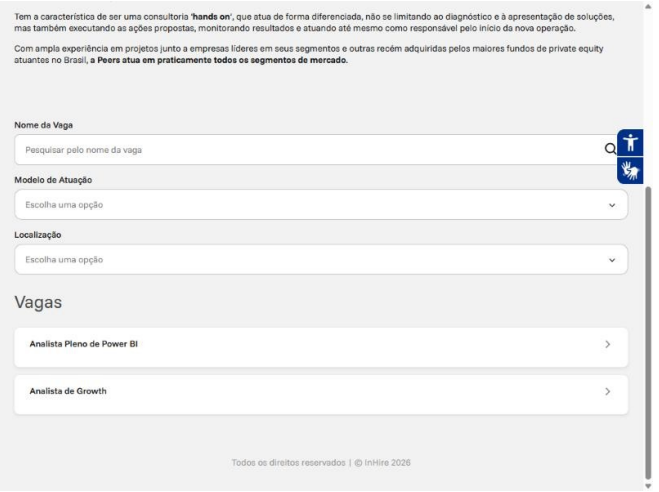
R$ 14.557

média mensal, 6.376 profissionais, +3,5% sobre 2025 (Portal Salário / CAGED, 05/11/2026)

R$ 11.500

mediana (P50); P10 R$ 4.199, P90 R$ 26.083; São Paulo mediana R$ 13.000 (Numerando / Novo CAGED, ref. 03/2026, 753 registros)

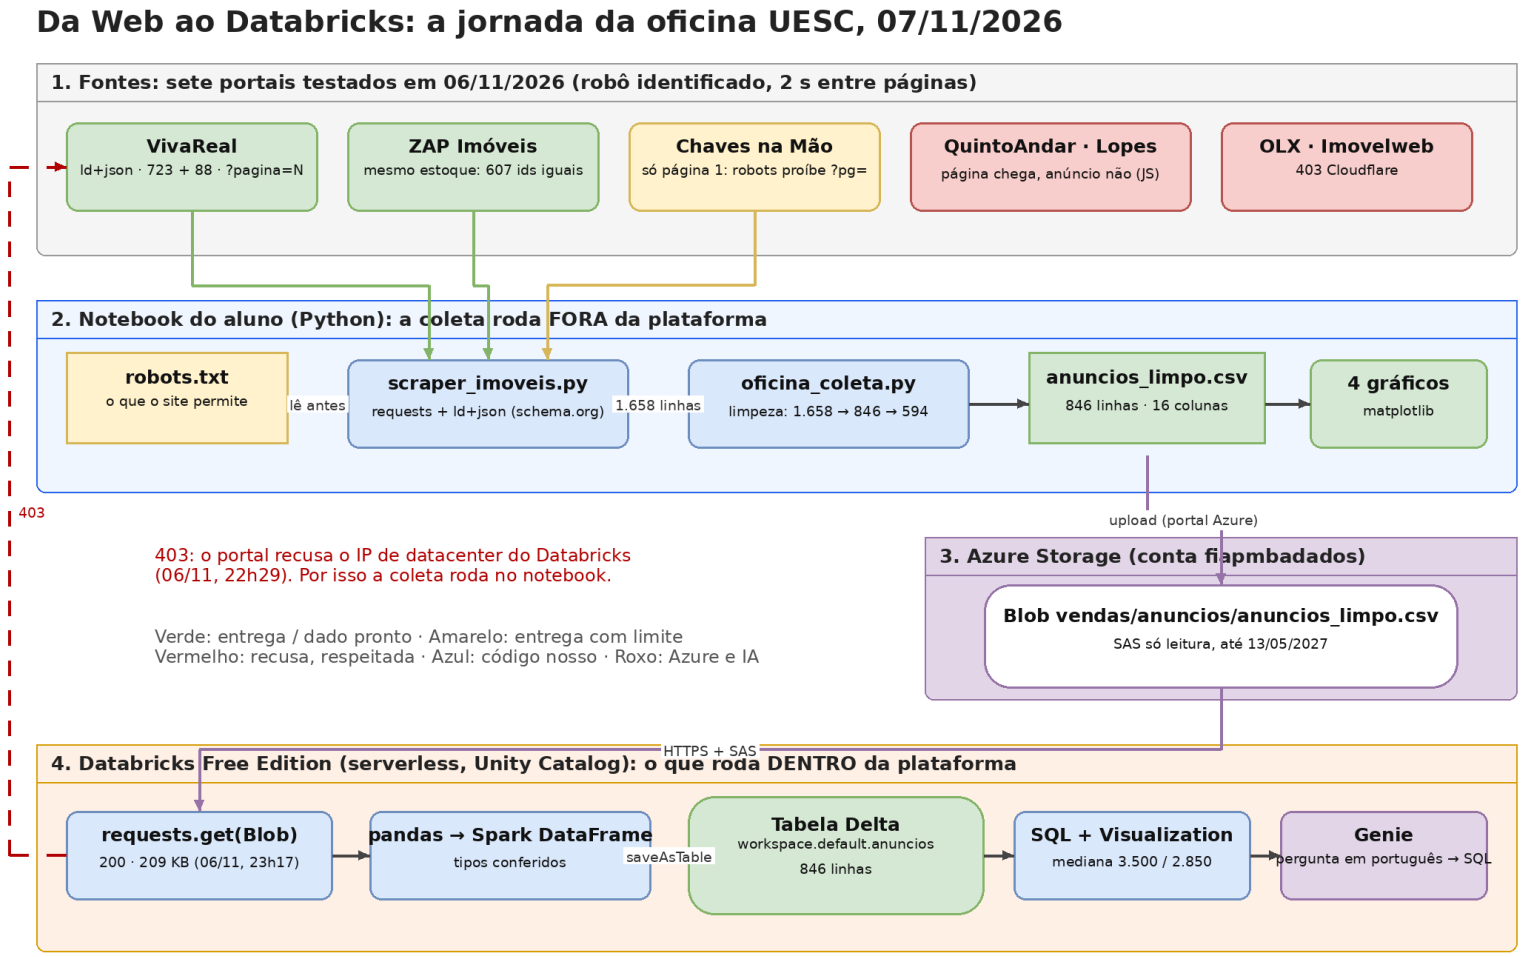
Média acima da mediana. Soa familiar? É a mesma estatística de ontem.



Onde eu trabalho. Vagas abertas em peers.inhire.app/vagas em 07/11/2026: Analista Pleno de Power BI, Analista de Growth; em Business Consulting: Sr. Analyst, Sr. Consultant, Manager. Vagas de engenharia de dados abrem por projeto: siga a página.

Dois avisos de quem é estatístico: salário de registro CLT não inclui PJ nem remoto para o exterior, que pagam mais; e Bahia não aparece nas tabelas por estado dessas fontes (amostra pequena). Fontes completas no slide final.

A jornada em um diagrama: o que roda fora e dentro



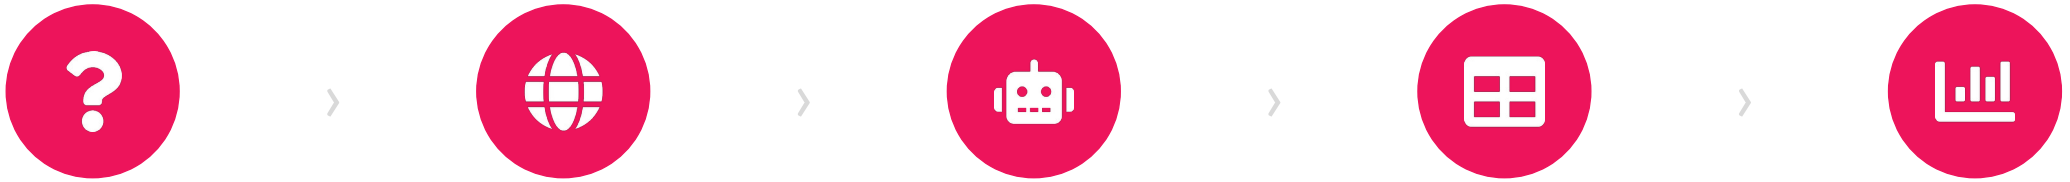
Quatro faixas

- Fontes: sete portais testados; três entregam, com regras diferentes.
- Notebook do aluno: robots.txt, coleta, limpeza, CSV. Roda fora porque o portal recusa o IP do Databricks (403).
- Azure Blob: o CSV vira um arquivo com SAS de leitura. Quem tem o link lê.
- Databricks: uma célula baixa, confere tipos e grava a tabela Delta. Daí SQL, gráfico e Genie.

Arquivo editável: docs/diagrama_jornada.drawio no repositório.

Uma pergunta, um caminho, quatro entregas

Quanto custa alugar em Ilhéus e em Itabuna, segundo o que está anunciado hoje?



Pergunta	Fonte	Coleta	Base	Análise
a de cima	VivaReal, e por quê	scraper_imoveis.py	anuncios_limpo.csv, tabela Delta	SQL, gráfico, Genie

Cada um sai daqui com:

- um CSV coletado por você, com data e hora
- uma tabela governada no Databricks Free Edition
- uma consulta SQL que responde a pergunta
- um espaço Genie onde a mesma pergunta é feita em português

Web scraping: pedir a página com um programa e ler

O navegador faz três coisas

Pede a página ao servidor (HTTP), recebe um texto enorme (HTML) e desenha. O scraper faz as duas primeiras e, em vez de desenhar, procura.

Três linhas

requests.get(url) pede. r.status_code diz se o site aceitou (200) ou recusou (403). r.text é o HTML inteiro, como texto.

Onde os dados estão

Da forma mais estruturada para a menos: ld+json (schema.org) › JSON embutido (__NEXT_DATA__) › HTML com classes. Quanto mais estruturado, menos adivinhação e menos quebra quando o site muda.

```
import requests
r = requests.get("https://www.vivareal.com.br/aluguel/bahia/ilheus/",
                 headers={"User-Agent": "oficina-uesc-estatistica/1.0 (uso
educacional)"})
print(r.status_code)   # 200 = aqui está; 403 = não; 429 = devagar
print(len(r.text))     # ~400 KB de HTML, como texto
```

Dois números para guardar: 200 é 'aqui está'. 403 é 'não'. Quando vem 403, o site decidiu não falar com você. A regra desta oficina é respeitar.

O método, para qualquer site

- 1. Ler o robots.txt
- 2. Pedir a página; olhar status e tamanho
- 3. Procurar os dados: ld+json › JSON embutido › HTML
- 4. Só JavaScript? F12 › Network, ou navegador automatizado honesto. Se nem assim, respeitar
- 5. Validar com UMA página antes de coletar tudo

Sete portais testados. Três entregam, e com regras

VivaReal	Cada página traz um bloco ld+json (schema.org) com 30 anúncios: id, preço, área, quartos, banheiros, tipo, bairro, URL. Paginação por ?pagina=N. 723 + 88 anúncios.	**Sim**
ZAP Imóveis	Mesmo formato, mesmo grupo, mesmo estoque: 607 ids iguais aos do VivaReal. Entra pela lição da duplicação.	**Sim**
Chaves na Mão	Entrega 159 anúncios em Ilhéus, mas o robots.txt proíbe qualquer query string e a paginação é ?pg=N. Só a página 1: 30 + 6.	**Sim, 1 página**
QuintoAndar e Lopes	Página chega, anúncio não: QuintoAndar embute JSON com a lista vazia; Lopes não tem um 'R$'. Com navegador automatizado identificado, idem.	**Não**
OLX e Imovelweb	403 (Cloudflare) para o robô identificado, até no robots.txt. Não se disfarça: ficam fora.	**Não**

Testes de 06/11/2026 do notebook do professor, robô identificado. O que a página mostra ao olho e o que ela entrega a um programa são coisas diferentes: a fonte escolhe você.

robots.txt: o que o site permite, em três casos reais

vivareal.com.br/robots.txt, lido em 06/11/2026

```
User-agent: *
Allow: /
Disallow: /*?*placeId=
Disallow: /*?*precoMaximo=
Disallow: /*?*quartos=
Disallow: /*?*ordem=
Disallow: /rent/
Disallow: /favorites
# (lista resumida)
```

VivaReal: o caminho /aluguel/bahia/ilheus/?pagina=N não está proibido; os filtros na URL estão. Filtramos no pandas. Chaves na Mão: 'Disallow: /*?*' proíbe qualquer '?', e a paginação é ?pg=N. Só a página 1: 30 de 159 anúncios, e é o permitido. OLX: até o robots.txt responde 403 ao nosso robô. Fora.

Como o nosso robô se comporta

- Diz quem é: User-Agent oficina-uesc-estatistica/1.0 (uso educacional)
- Espera 2 segundos entre páginas; no máximo 30 páginas por cidade
- Guarda só atributos do imóvel. Nome e telefone de anunciante não entram
- Se o site responder 403 ou 429, para. Não troca de IP, não se disfarça
- robots.txt é a convenção técnica; termos de uso e LGPD (art. 5°, I; art. 7°, §4°) são outras camadas. Uso educacional, sem redistribuição

O que o robô lê: um anúncio real, como o portal o publica

```
<script type="application/ld+json">
{ "@type": "ItemList", "numberOfItems": 30,
  "itemListElement": [ { "item": {
    "@id": "2902416120",
    "additionalType": "https://schema.org/Apartment",
    "address": { "addressLocality": "Ilhéus",
                 "addressRegion": "BA" },
    "offers": { "price": 4500, "priceCurrency": "BRL" },
    "floorSize": { "value": 76, "unitCode": "M2" },
    "numberOfBedrooms": 2,
    "numberOfBathroomsTotal": 2,
    "keywords": "... em Nossa Senhora da Vitória, Ilhéus",
    "url": "https://www.vivareal.com.br/imovel/..." } },
  ... ] }
</script>
```

De cada anúncio, 13 colunas

```
portal
id_anuncio
cidade
bairro_texto    (de keywords)
bairro_url      (da URL)
tipo            (additionalType)
preco           (offers.price)
area_m2         (floorSize)
quartos
banheiros
pagina
url
coletado_em
```

schema.org é um vocabulário feito para programas lerem. Quando o site publica assim, não há HTML para adivinhar.

Trecho real da página 1 de Ilhéus, 06/11/2026, abreviado. O anúncio 2902416120 volta a aparecer no slide 8.

scraper_imoveis.py: três funções e um laço com pausa

```
UA = {"User-Agent": "oficina-uesc-estatistica/1.0 (uso educacional)"}
PAUSA = 2.0
BASE = "https://www.vivareal.com.br/aluguel/bahia/{cidade}/"

def extrair_pagina(html, cidade, pagina):
    soup = BeautifulSoup(html, "lxml")
    for sc in soup.select("script[type='application/ld+json']"):
        d = json.loads(sc.string)
        if d.get("@type") != "ItemList": continue
        for el in d["itemListElement"]:
            it = el["item"]
            registros.append({"id_anuncio": it["@id"],
                "preco": it["offers"]["price"],
                "area_m2": it["floorSize"]["value"], ...})

def coletar(cidade, max_paginas=30):
    for p in range(1, max_paginas + 1):
        r = requests.get(BASE + f"?pagina={p}", headers=UA)
        regs = extrair_pagina(r.text, cidade, p)
        if not regs: break
        time.sleep(PAUSA)
```

`extrair_pagina`

acha o ld+json, lê os 30 itens, devolve dicionários

`coletar`

laço de páginas; para na primeira vazia; dorme 2 s

`salvar`

CSV com cabeçalho, UTF-8, uma linha por anúncio

```
python scraper_imoveis.py ilheus 5
python scraper_imoveis.py itabuna 5
python scraper_imoveis.py
```

Código abreviado para o slide; o arquivo completo tem 90 linhas e está na pasta da oficina.

O que a coleta devolveu em 06/11/2026, 23h38 a 23h42

1.658

linhas, três portais

VivaReal 723 + 88, ZAP 723 + 88, Chaves na Mão 30 + 6. O VivaReal anuncia 'mais de 726' em Ilhéus; vieram 723.

196 s

de coleta

60 requisições com 2 s de pausa entre elas. Sem bloqueio, sem erro.

846

anúncios únicos

1.658 linhas, 812 ids repetidos. Entre páginas e, sobretudo, entre portais.

```
vivareal ilheus pagina 1: 30 anuncios
...
vivareal ilheus pagina 25: 3 anuncios
vivareal ilheus pagina 26: 0 anuncios
zap ilheus pagina 1: 30 anuncios
...
chavesnamao ilheus pagina 1: 30 anuncios (so a pagina 1)
1658 linhas coletadas em 196 s
```

1.658 linhas. São 846 anúncios.

Antes de calcular qualquer média, a base precisa ser olhada. O próximo slide mostra quatro coisas que ela esconde, todas descobertas nessa execução.

Quatro coisas que as 1.658 linhas escondem

812 ids repetidos

VivaReal e ZAP são o mesmo estoque: 607 ids nos dois. E o mesmo anúncio cai em duas páginas quando o portal reordena a lista entre requisições. 1.658 vira 846.

Bairro com duas grafias

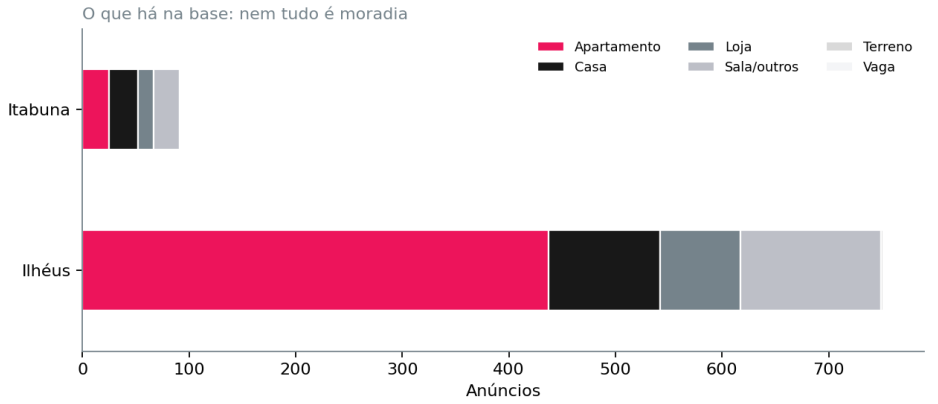
No VivaReal o bairro vem da URL, sem acento; no ZAP e no Chaves na Mão vem do texto, com acento. 'Nossa Senhora da Vitória' virava dois bairros. Padronizar sem acento.

Nem tudo é moradia

462 apartamentos, 132 casas, 156 salas e galpões, 90 lojas, terrenos, vaga. E no Chaves na Mão o schema.org chama galpão de 'Accommodation': o tipo veio da URL. 594 residenciais.

Galpões de R$ 90.000 e R$ 60.000

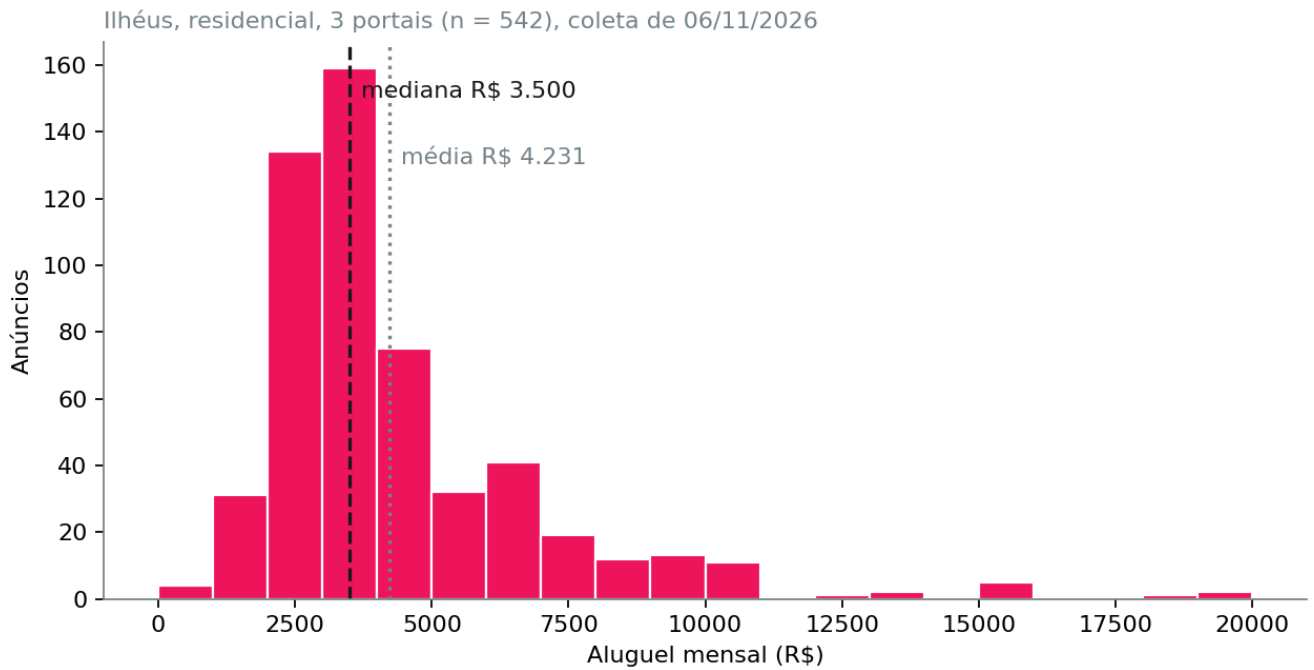
Iguape (Ilhéus) e Ferradas (Itabuna). Puxam a média bruta: Itabuna R$ 6.678 contra Ilhéus R$ 4.780, Itabuna parecia mais cara. Não é.




```
df.id_anuncio.duplicated().sum()   # 812
limpo = df.drop_duplicates("id_anuncio")  # 846
limpo["bairro"] = sem_acento(bairro).title()
limpo["residencial"] = limpo.tipo.isin(
    ["Apartment", "House", "Accommodation"])
res = limpo[limpo.residencial
            & (limpo.area_m2 > 0)]   # 594
```

Execução de 06/11/2026, 23h44. Nenhuma das quatro é 'estatística' no sentido da prova; todas mudam o número final.

Residencial, sem duplicata: a média e a mediana discordam



Cidade	n	média	mediana	R$/m² mediano
Ilhéus	542	R$ 4.231	R$ 3.500	R$ 40,0
Itabuna	52	R$ 4.457	R$ 2.850	R$ 18,6

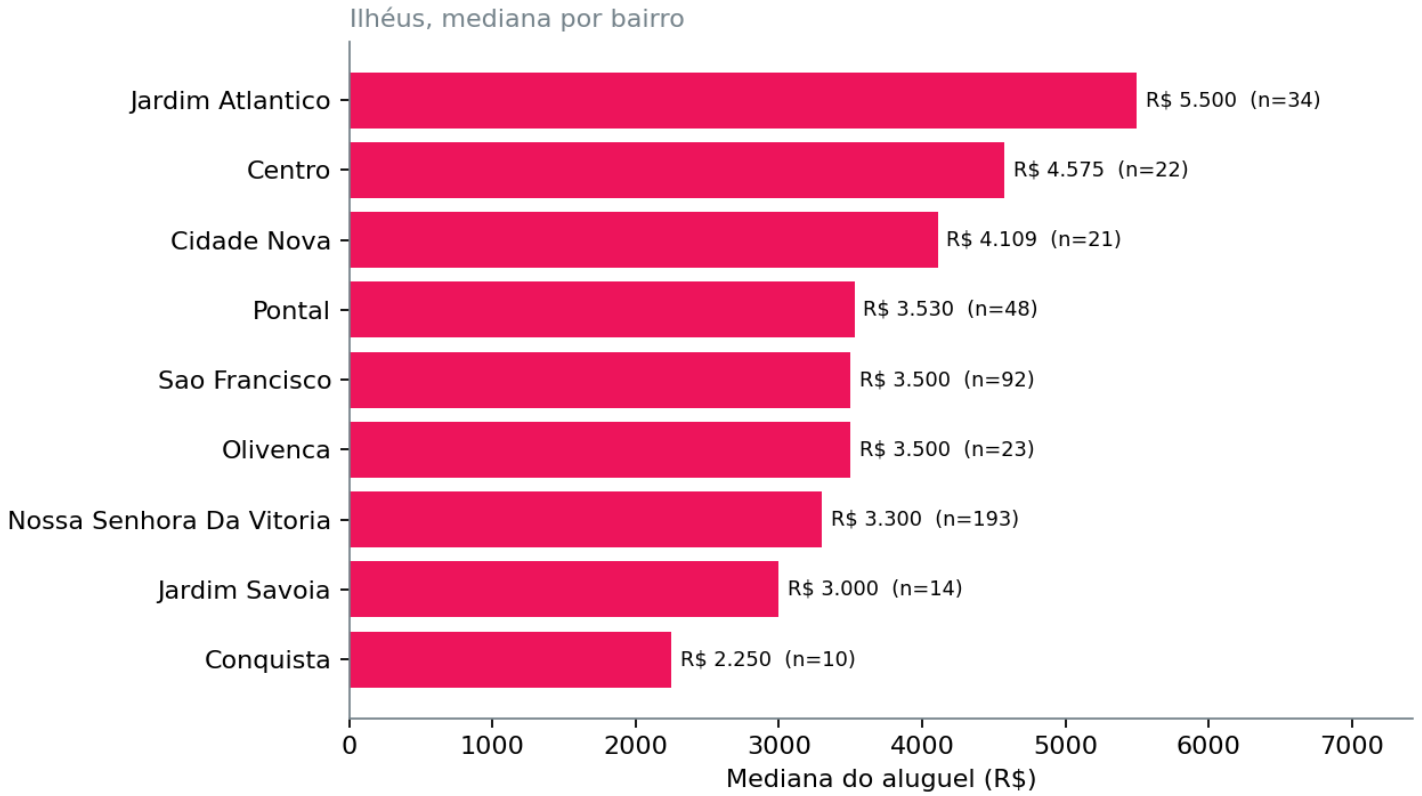
Leitura

- A mediana de Itabuna é R$ 650 menor que a de Ilhéus; a média diz o contrário. Com 52 anúncios, quatro casas caras bastam para isso.
- Por metro quadrado, Ilhéus custa mais que o dobro de Itabuna. Esse número aguenta melhor o outlier.
- Mínimo R$ 300 em Ilhéus: quarto ou kitnet, ou erro de digitação do anunciante. Conferir pela URL.

```
res = limpo[limpo.residencial & (limpo.area_m2 > 0)]
res.groupby("cidade").preco.agg(["count","mean","median","std","min","max"])
(res.preco / res.area_m2).groupby(res.cidade).median()
```

VivaReal, ZAP e Chaves na Mão, 06/11/2026. Anúncios únicos, residenciais, com área informada. Valores em R$ por mês.

Ilhéus por bairro: o número e a pergunta que fica



Bairros com 10 ou mais anúncios residenciais. Nomes padronizados sem acento. Mediana em R$ por mês, 06/11/2026.

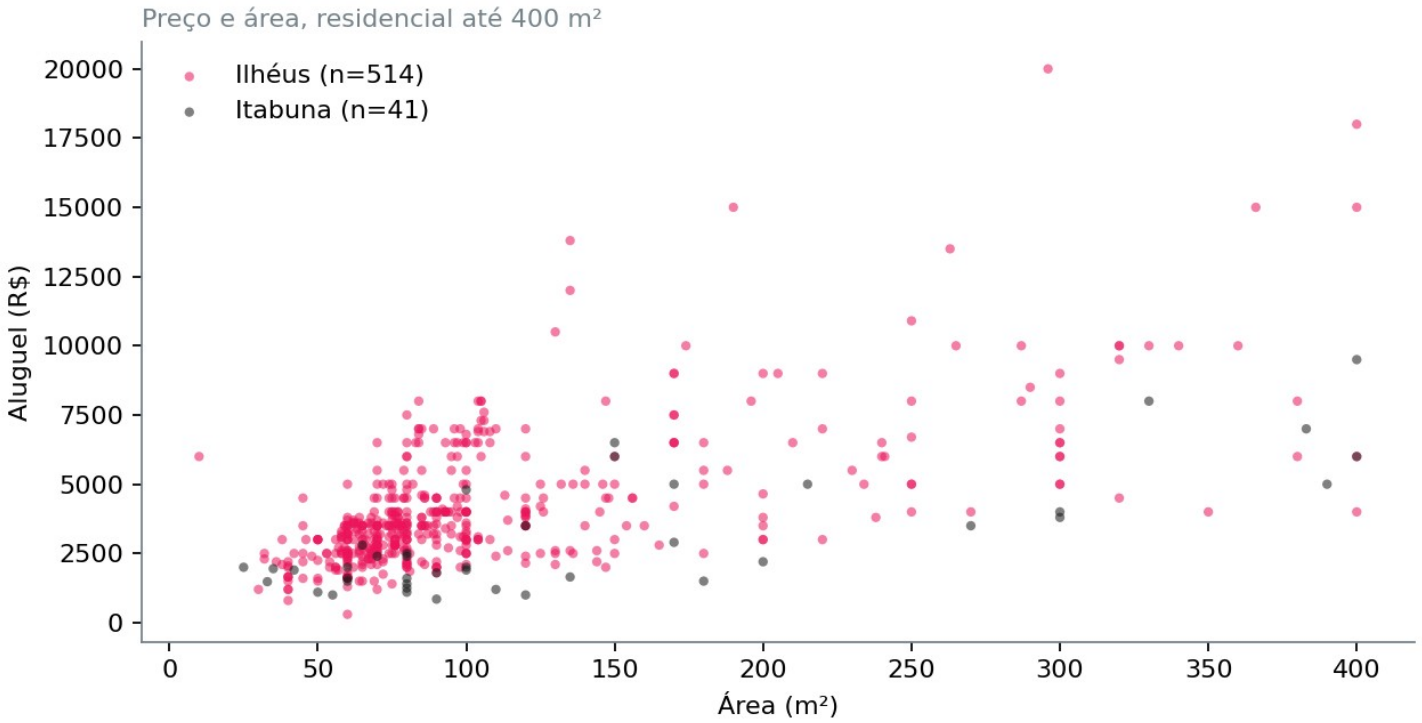
193 contra 34

Nossa Senhora da Vitória tem 193 anúncios residenciais; Jardim Atlântico, 34.

Isso diz que há mais imóveis lá? Ou que há mais imóveis anunciados neste portal lá?

É a mesma pergunta de ontem (população-alvo contra população amostrada), agora com um bairro que a turma conhece.

Preço e área: a nuvem que a média esconde



Residencial, até 400 m², para a nuvem caber: 514 dos 542 anúncios de Ilhéus e 41 dos 52 de Itabuna. 06/11/2026.

O que a turma pode fazer com isso

- Regressão de preço em área, quartos e bairro: a base tem as colunas.
- Resíduos grandes são anúncios para olhar um a um: erro de digitação, imóvel de luxo, área errada.
- Comparar a inclinação entre as duas cidades: é o R$/m² do slide 9, visto de outro ângulo.
- Repetir a coleta daqui a uma semana: nasce uma série temporal.

Databricks em cinco frases, para quem já ouviu falar





Nasceu do Spark

Criada em 2013 pelos criadores do Apache Spark (UC Berkeley). Spark divide o trabalho entre muitas máquinas e processa em memória: 100 estagiários organizando planilhas ao mesmo tempo, em vez de um.



Lakehouse

Arquivos baratos na nuvem (como um data lake) com, por cima, o que um warehouse tem: tabelas com transação, histórico e governança. Armbrust et al., CIDR 2021.



Delta Lake

O formato de tabela: Parquet mais um diário de transações (_delta_log). Cada escrita fica registrada; dá para voltar no tempo. VLDB 2020.



Unity Catalog

O prédio de arquivos: catálogo › schema › tabela ou volume, com dono e permissão em cada nível. A nossa: workspace.default.anuncios.



Serverless

Na Free Edition a computação liga quando você roda uma célula e desliga sozinha. A primeira célula demora um minuto; as seguintes, segundos.

Fontes: databricks.com (empresa), papers de Armbrust et al. (CIDR 2021, VLDB 2020), documentação do Free Edition lida em 05 e 06/11/2026.

Velocidade: hoje o custo fixo, na escala o ganho

Hoje, com 846 linhas

- Primeira célula: ~1 minuto. É o serverless ligando (custo fixo), não a consulta.
- Célula do Blob: baixar 209 KB, converter e gravar a tabela levou 33 s na conta do professor (06/11, 23h59), quase tudo ligação do compute.
- Consultas SQL seguintes: segundos.
- Qualquer laptop faria as mesmas contas em milissegundos. Não é aqui que a plataforma ganha.

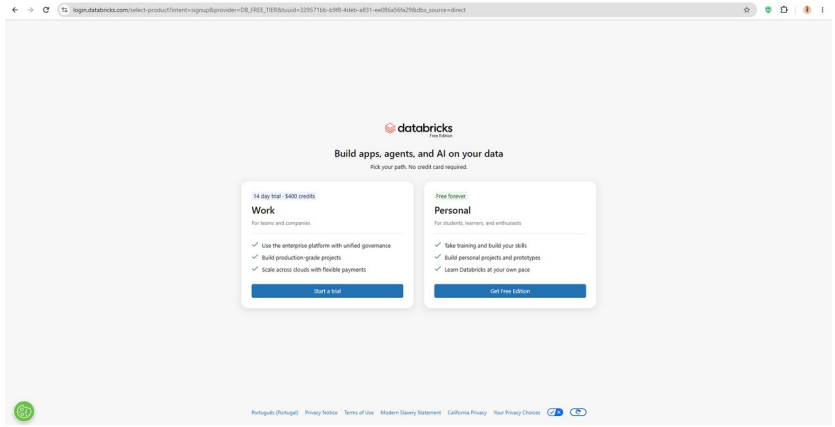
O que você vê hoje é o custo fixo. O ganho aparece na escala.

Com 846 milhões de linhas

- A mesma consulta, a mesma sintaxe. O Spark distribui o trabalho entre máquinas e o Delta lê só as colunas e os arquivos necessários.
- Sem trocar de ferramenta quando o CSV não cabe mais no Excel, nem quando não cabe mais no pandas.
- Casos brasileiros publicados pela Databricks (comunicados de 01/07/2025 e 03/09/2025, conferidos 05/11/2026): Cielo, 6.500 pipelines e 3.000 jobs eliminados, 40% menos tempo de ingestão; Casas Bahia, 70% de redução de custo na migração do SAS; Natura, ciclo de relatórios 64% mais curto.

Números de empresas vêm da própria Databricks: são casos de sucesso, não auditoria independente. Diga isso.

Criar a conta Free Edition: cinco minutos, quatro telas reais



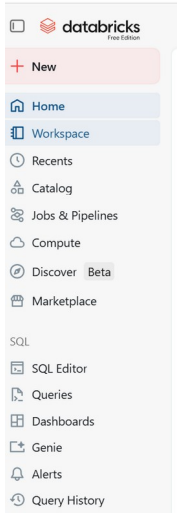
1. databricks.com/try-databricks › lado Personal, 'Free forever' › Get Free Edition. Não o trial de 14 dias.

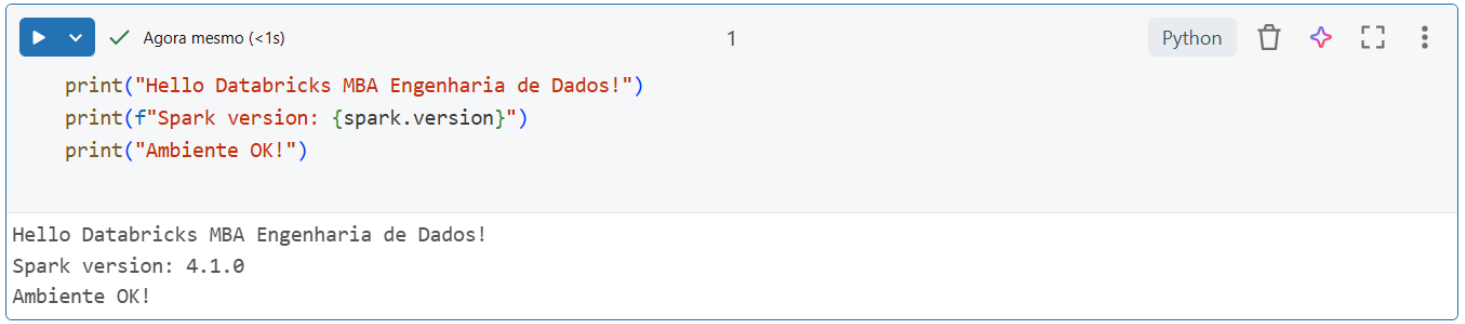


2. Login com Google, Microsoft ou e-mail (código de 6 dígitos). Finalidade: uso pessoal.

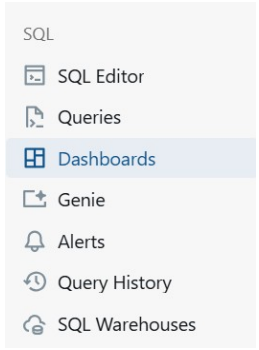


3. 'Estamos configurando sua conta': menos de um minuto.





4. New › Notebook, Python, compute Serverless. A primeira célula demora um minuto. Depois, segundos.



O mapa da barra lateral: Workspace (seus notebooks), Catalog (tabelas e volumes), SQL Editor, Genie. Tudo o que usamos hoje está aí.

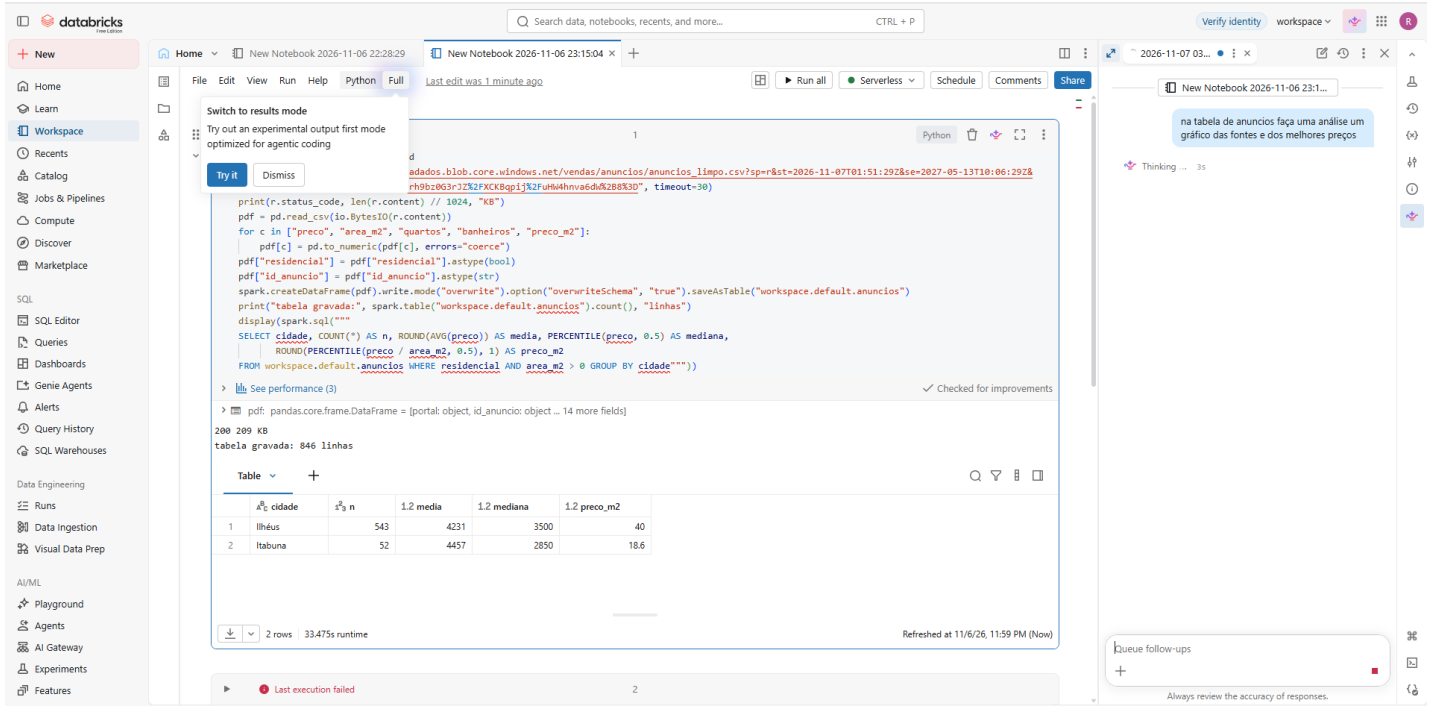
Capturas reais da conta do professor (Free Edition, 2026). Limites: só serverless, 1 warehouse 2X-Small, internet de saída restrita, uso não comercial.

Dois testes reais: 403 do portal, 200 do Blob

```
Just now (1s)
import requests
UA = {"User-Agent": "oficina-uesc-estatistica/1.0 (uso educacional)", "Accept-Language": "pt-BR,pt;q=0.9"}
try:
    r = requests.get("https://www.vivareal.com.br/aluguel/bahia/ilheus/", headers=UA, timeout=20)
    print(r.status_code, "| tamanho:", len(r.text) // 1024, "KB | ld+json encontrado:", "application/ld+json" in r.text)
except Exception as e:
    print("SEM ACESSO:", type(e).__name__, str(e)[:300])

403 | tamanho: 5 KB | ld+json encontrado: False
```

22h29: requests.get no VivaReal, de dentro do Databricks. 403, 5 KB, sem ld+json. A rede chegou ao site; o site recusou o IP de datacenter (Cloudflare). Por isso a coleta roda no notebook.



23h59: uma célula, do Blob à tabela

- requests.get no Azure Blob com SAS de leitura: 200, 209 KB.
- pandas lê; tipos conferidos (preço e área numéricos, quartos e banheiros com NULL, residencial booleano).
- spark.createDataFrame › saveAsTable: tabela gravada, 846 linhas.
- A consulta já responde: Ilhéus 543* / 4231 / 3500 / 40; Itabuna 52 / 4457 / 2850 / 18,6.
- Runtime 33 s, quase tudo o serverless ligando.

** 543 na tela, 542 nas consultas finais: a consulta do print não excluía preço nulo (um anúncio 'sob consulta' do Chaves na Mão). As consultas do repositório já excluem. Está dito, não escondido.*

Databricks Free Edition: da planilha à tabela governada

1. O CSV está no Azure Blob

O Free Edition alcança o Blob (testado 06/11, 23h17). Uma célula lê o CSV com um SAS de leitura e grava workspace.default.anuncios. Ninguém faz upload.

2. A tabela Delta

pandas lê, Spark grava. Tipos conferidos: preco e area_m2 numéricos; quartos e banheiros com NULL; residencial BOOLEAN. 846 linhas.

3. A pergunta em SQL

No notebook SQL importado, com o warehouse serverless (liga sozinho, pode levar um minuto).

4. Visualizar

+ Visualization na própria consulta: barras de mediana por bairro. Mesmo número do matplotlib, outro caminho.

```
SELECT cidade, COUNT(*) AS n,
       ROUND(AVG(preco)) AS media,
       PERCENTILE(preco, 0.5) AS mediana,
       ROUND(PERCENTILE(preco / area_m2, 0.5), 1) AS preco_m2
FROM workspace.default.anuncios
WHERE residencial AND area_m2 > 0 AND preco IS NOT NULL
GROUP BY cidade;

-- esperado:
-- Ilhéus   542  4231  3500  40.0
-- Itabuna   52  4457  2850  18.6
```

O que mudou da planilha para cá não foi a conta

Foi a governança: a tabela tem dono, histórico (Delta), permissão, e qualquer pessoa da equipe faz a mesma pergunta sobre o mesmo dado. Free Edition: só serverless, 1 warehouse 2X-Small, uso não comercial. A coleta rodou fora: o VivaReal respondeu 403 ao notebook serverless (06/11, 22h29). O Blob da Azure respondeu 200 (23h17): quem fala com a internet é decisão da plataforma.

Limites lidos na documentação em 06/11/2026; testes de rede (VivaReal 403, Blob 200) feitos na conta do professor em 06/11/2026.

Genie: a mesma pergunta, em português, e o SQL gerado

Criar o espaço

Genie > New, escolher workspace.default.anuncios.

Ensinar o que a tabela não diz

Instruções em português (ao lado).

Perguntar na frente da turma

'Qual a mediana do aluguel residencial em Ilhéus e Itabuna?' Conferir: 3.500 e 2.850.

Mostrar sempre o SQL gerado

Genie não sabe a resposta. Ele escreve a consulta a partir dos metadados e das instruções. Instrução errada, resposta errada com a mesma confiança.

Instruções do espaço (Configure > Instructions)

- preco é o aluguel mensal em reais (BRL); area_m2 em metros quadrados.
- residencial = true significa Apartment ou House. Para perguntas sobre moradia, filtre residencial = true.
- Dados dos portais VivaReal, ZAP e Chaves na Mão, coletados em 06/11/2026. Não representam todos os imóveis da cidade, só os anunciados nesses portais.
- Prefira mediana a média: há outliers (galpões de até R$ 90.000).

O que verifiquei e o que não

Genie está na lista de recursos da página do Free Edition (docs, 06/11/2026) e a página de limitações não o restringe. Não abri o Genie numa conta Free Edition antes da oficina. Plano B: o Assistant do editor SQL, que também escreve SQL a partir de pergunta em português, e a mesma lição.

Outras perguntas para o Genie: os 5 bairros de Ilhéus com mais anúncios; o preço por m² em cada cidade; o apartamento de 2 quartos mais barato no Pontal.

Genie: por que importa, e por que exige cuidado



O que é

A interface de linguagem natural do Databricks sobre tabelas do Unity Catalog. Você pergunta em português; ele escreve o SQL, executa e devolve tabela ou gráfico. Listado como recurso da Free Edition (docs, 06/11/2026).

Por que importa

- É como o negócio consome o que o engenheiro construiu: sem esperar o analista escrever a consulta.
- Funciona sobre a tabela governada: a mesma que o SQL usa, com as mesmas permissões.
- Mostra o SQL gerado: dá para auditar cada resposta.
- O valor do engenheiro de dados sobe, não desce: sem tabela limpa, tipada e documentada, a IA responde errado com confiança.

Por que exige cuidado: o que o Genie não sabe

- Que 'preco' é aluguel mensal em reais, e não venda.
- Que 'residencial' precisa ser filtrado quando a pergunta é sobre moradia.
- Que os dados são de três portais, numa data, e não 'de Ilhéus'.
- Que há galpões de R$ 90.000 puxando a média.

Ele escreve a consulta a partir dos metadados (nomes e tipos das colunas) e das instruções do espaço. Instrução errada, resposta errada, com a mesma cara. Na oficina: tire a instrução de 'residencial' e repita a pergunta. A mediana muda.

Não abri o Genie numa conta Free Edition antes da oficina. Plano B: o Assistant do editor SQL, mesma lição.

Para discutir: cinco perguntas sem resposta pronta

1. A coleta rodou fora por causa de um 403. Numa empresa, quem decide por onde o dado entra: o engenheiro que escreve o script ou a plataforma? O que muda em segurança e em custo?

2. O SAS do Blob dá leitura do container até 2027 a quem tiver o notebook. Aceitável para anúncios públicos? E se fossem dados de clientes?

3. O Genie respondeu certo com a instrução certa e errado sem ela. Quem responde pela resposta errada: a IA, quem configurou o espaço, ou quem perguntou?

4. Ilhéus tem 723 anúncios no portal e Itabuna 88. O que isso diz sobre as cidades? E sobre o portal?

5. Média bruta de Itabuna R$ 6.678, mediana residencial R$ 2.850. Qual vai para a manchete, qual para a decisão de alugar, qual para o modelo de regressão?

Escolha duas. Dez minutos. A resposta boa começa com 'depende de...' e termina com um dado.

Tudo o que rodou hoje está no GitHub, para rodar de novo

```
oficina-uesc-databricks/
├── README.md                  comece por aqui
├── coleta/                    roda no SEU computador
│   ├── scraper_imoveis.py     coletor comentado linha a linha
│   ├── oficina_coleta.py      um comando: coleta + limpeza + gráficos
│   ├── rodar_coleta.bat       Windows: dois cliques
│   └── requirements.txt
├── databricks/                roda DENTRO do Databricks
│   ├── blob_para_databricks.py
│   ├── oficina_sql_notebook.sql
│   └── scraper_databricks_notebook.py   (o 403)
├── dados/                     anuncios_limpo.csv, saída, gráficos
└── docs/                      passo a passo, scraping explicado,
                               jornada Databricks, diagrama, PDF
```

Três documentos para o aluno

- 01 Passo a passo: 10 passos, do pip install ao Genie, com o que deve aparecer em cada um.
- 02 Web scraping explicado: HTTP, robots.txt, ld+json, as cinco regras do robô, as quatro armadilhas da base.
- 03 Databricks, a jornada: o que é, como funciona, a conta com telas reais, Blob, Delta, Genie, perguntas para discussão.

Em três comandos:

```
cd coleta
python -m pip install -r requirements.txt
python oficina_coleta.py --rapido
```

github.com/rafsp · endereço do repositório anunciado na oficina

Desafio para casa: repita a coleta daqui a uma semana. Quantos anúncios saíram? Quantos entraram? A mediana mudou? Isso é uma série temporal nascendo.

1.658 linhas. 594 bons dados. Quatro decisões no meio

Fonte que entrega. Caminho permitido. Sem duplicata. Só moradia. Mediana, não média.

1.658
linhas, 3 portais

› **846**
anúncios únicos

› **594**
residenciais

› **R$ 3.500**
mediana em Ilhéus

Fontes, arquivos e o que não verifiquei

Fontes e datas

- Coleta: VivaReal, ZAP e Chaves na Mão, Ilhéus e Itabuna, 06/11/2026, 23h38 a 23h42, 1.658 linhas, 846 anúncios únicos.
- Testes de portais em 06/11/2026: requests (sete portais) e Playwright identificado (QuintoAndar, Lopes).
- robots.txt do VivaReal, ZAP, Chaves na Mão, QuintoAndar e Lopes: lidos em 06/11/2026.
- Databricks Free Edition: docs lidas em 05 e 06/11/2026; testes na conta do professor em 06/11: VivaReal 403 (22h29), Azure Blob 200 (23h17).
- LGPD: Lei 13.709/2018, art. 5°, I e art. 7°, §4°, planalto.gov.br.
- Salários: Portal Salário (CAGED), CBO 2122-05, atualizado 05/11/2026; Numerando (Novo CAGED, ref. 03/2026). Vagas: peers.inhire.app/vagas, 07/11/2026.
- Telas do Databricks: conta do professor, 2026. Foto da capa: Leandro M800, CC0, Wikimedia Commons.

O que não verifiquei

- Genie aberto numa conta Free Edition (só a documentação).
- A célula que grava a tabela a partir do Blob (createDataFrame e saveAsTable) na conta Free Edition: a leitura do Blob foi testada, a gravação não.
- Termos de uso dos portais sobre coleta automatizada (li só os robots.txt).
- QuintoAndar e Lopes com navegador disfarçado de humano: não testado, de propósito.
- A diferença entre os totais do portal (726, 89) e os coletados (723, 88); e o 543 do print contra os 542 das consultas finais (um anúncio com preço nulo).
- Os casos de empresas (Cielo, Casas Bahia, Natura) são comunicados da própria Databricks, não auditoria independente.

```
Pasta Oficina: oficina_coleta.py, scraper_imoveis.py,
anuncios_limpo.csv, g1 a g4.png, blob_para_databricks.py,
oficina_sql_notebook.sql, Passo_a_Passo_60min.md
```