Universidade Estadual de Santa Cruz
Bloco 3 da oficina · Apoio FIAP

Uma pipeline de dados, do começo ao fim

CRISP-DM na prática: prever o aluguel em Ilhéus e Itabuna com os 594 anúncios que coletamos

Rafael Santos Novo Pereira
Estatística e IA na Prática · UESC, LEC · 07/11/2026



Ilhéus. Foto: turismobahia, CC BY-SA 2.0, Wikimedia Commons.

Quanto paga o mercado: analista, cientista, engenheiro

Analista de dados

R$ 5.500

média mensal, 2.717 salários no Glassdoor (citado por Data Hackers). Júnior R$ 3.800, pleno R$ 5.300, sênior R$ 10.100 em vagas públicas (levantamento DataHire Club, 2026).

Não há CBO próprio: o CAGED não separa 'analista de dados'. O mais próximo, 'Estatístico analista' (CBO 2112-05): média R$ 8.380, +16% sobre 2025 (Portal Salário / CAGED, 06/2025 a 05/2026).

Cientista de dados

R$ 11.080

média mensal, 1.687 profissionais, +2,3% sobre 2025. Piso R$ 7.365, teto R$ 18.981 (Portal Salário / CAGED, CBO 2031-05, 06/2025 a 05/2026).

Mediana R$ 8.000; P10 R$ 3.001, P90 R$ 17.643; São Paulo mediana R$ 11.250 (Numerando / Novo CAGED, ref. 01/2026). Média acima da mediana: cauda à direita.

Engenheiro de dados

R$ 14.557

média mensal, 6.376 profissionais, +3,5% sobre 2025. Piso R$ 9.593, teto R$ 26.180 (Portal Salário / CAGED, CBO 2122-05, atualizado 05/11/2026).

Mediana R$ 11.500; P90 R$ 26.083 (Numerando / Novo CAGED, ref. 03/2026). Quem constrói a base ganha mais que quem só a analisa: o mercado paga a pipeline.

Salário base CLT registrado; PJ e remoto para o exterior pagam mais e não entram. Bahia não aparece por estado nessas fontes (amostra pequena). Glassdoor exige login; o número do analista vem de citação secundária e está marcado como tal.

CRISP-DM: seis fases, e a nossa pipeline em cada uma

1. Entendimento do negócio

Quanto custa alugar em Ilhéus e Itabuna? Um modelo que dê um preço de referência para um imóvel novo.

2. Entendimento dos dados

7 portais testados, 3 entregam. 1.658 linhas, 846 únicos, 594 residenciais. Mediana R$ 3.500 e R$ 2.850.

3. Preparação

Filtro residencial, bairros raros viram 'Outros', imputação, treino/teste 80/20, one-hot, standard scaler.

4. Modelagem

Regressão linear e árvore de decisão, no mesmo pré-processamento, com uma linha de base para vencer.

5. Avaliação

MAE, RMSE e R^2 no teste. Linear: MAE R$ 1.242, R^2 0,56. Árvore: MAE R$ 1.143, R^2 0,49.

6. Implantação

pipeline.predict() em anúncios novos. E a pergunta: esse erro serve para quem?

CRISP-DM (Cross-Industry Standard Process for Data Mining, Chapman et al., 2000): o processo é um ciclo; a avaliação devolve você ao negócio.

Fase 1. Negócio: a pergunta antes do modelo

Dado um imóvel (cidade, bairro, tipo, área, quartos, banheiros), qual aluguel mensal é esperado, segundo o que está anunciado?

Inquilino

'Esse anúncio está caro ou barato para o que é?' Precisa de um erro pequeno em imóveis comuns, não em coberturas.

Imobiliária

'Por quanto anuncio?' Precisa de referência por bairro e tipo, e do intervalo, não só do número.

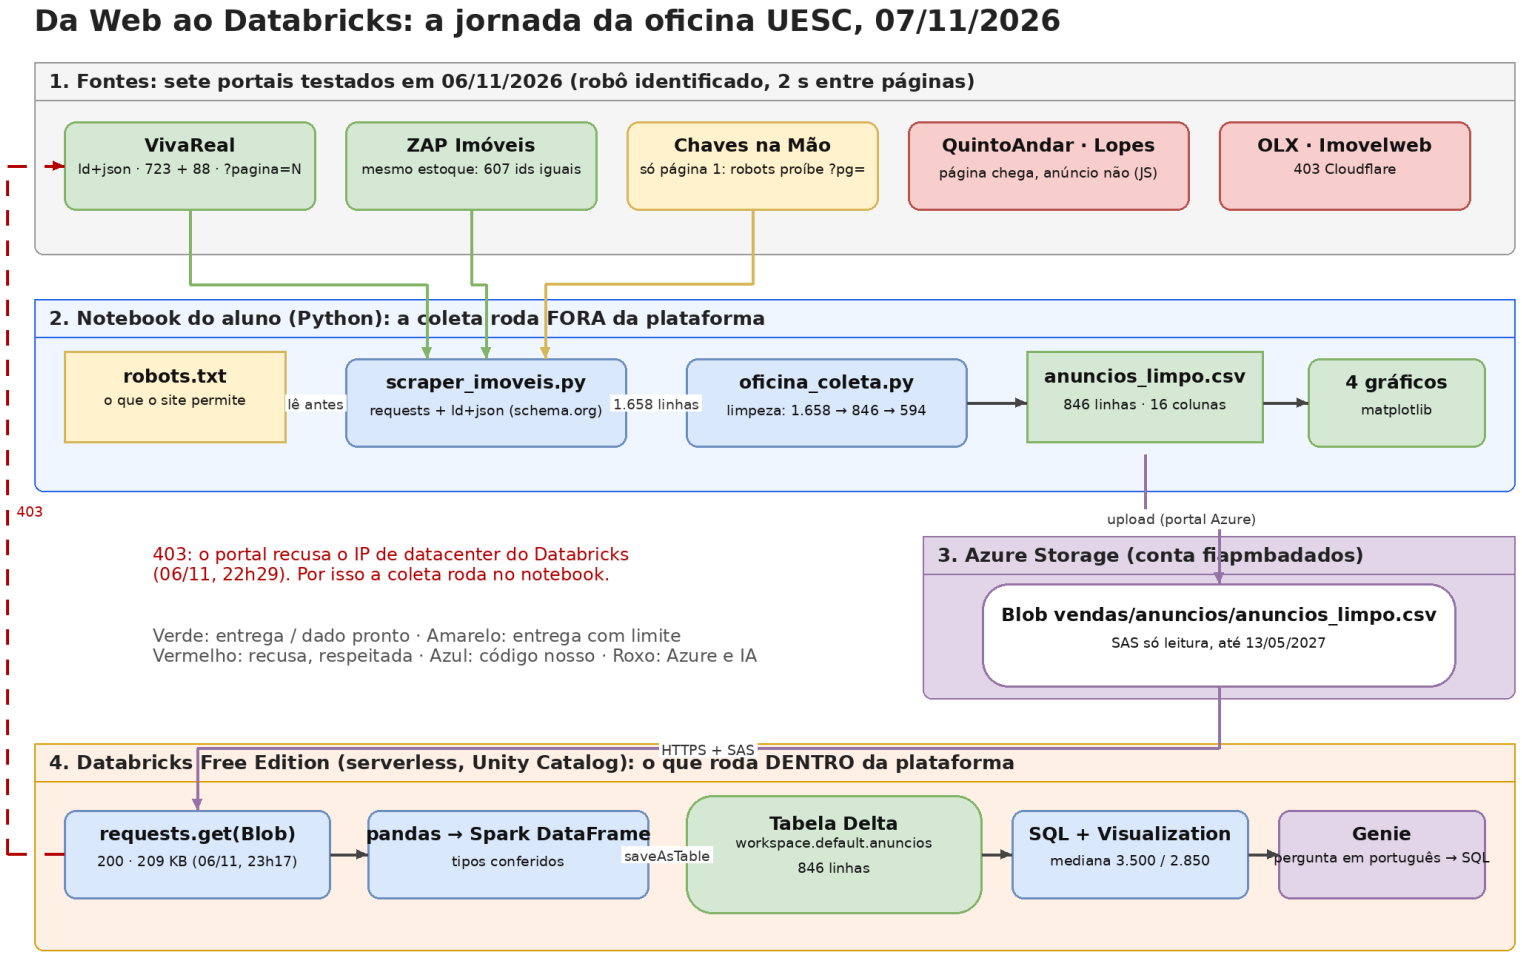
Pesquisador / prefeitura

'O aluguel subiu?' Precisa da série no tempo e sabe que portal não é censo.

O que o modelo NÃO vai saber, antes de começar

- Condomínio, IPTU, mobília, andar, vista, estado de conservação: não estão na base.
- Preço anunciado não é preço fechado: o portal mostra a oferta, não o contrato.
- Só 3 portais, numa data. População anunciada, não a cidade.

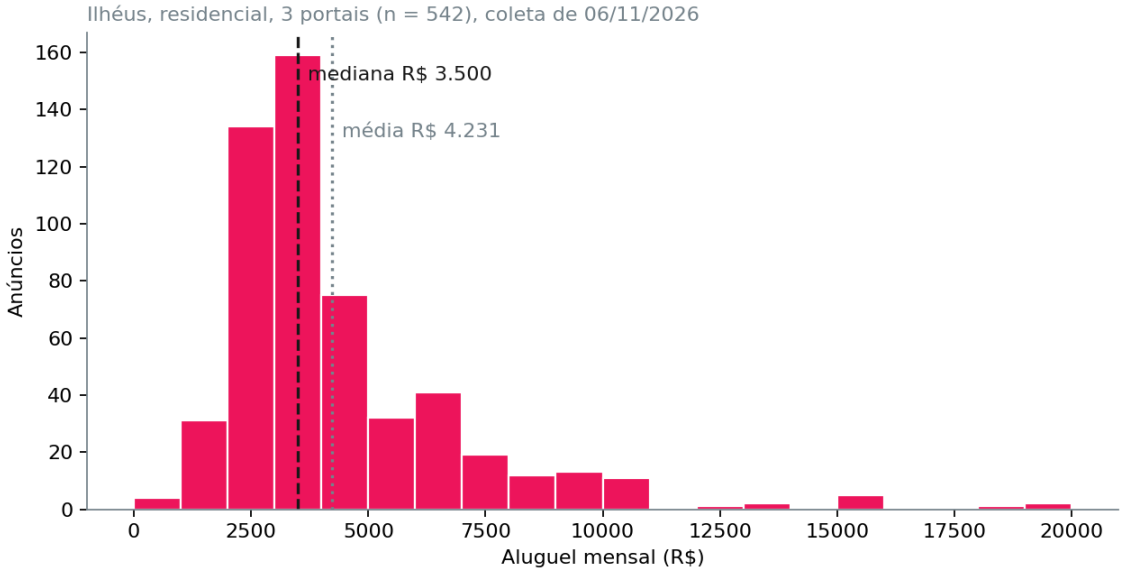
Fase 2. Coleta: a pipeline que alimenta o modelo

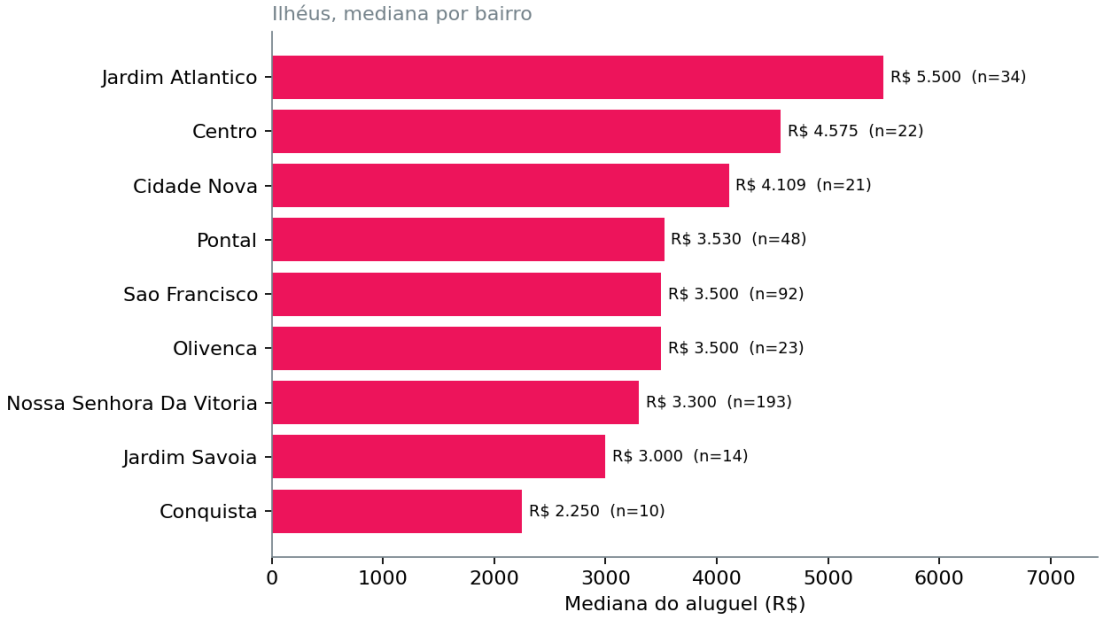


O que chega à fase 3

- 3 portais entregam (VivaReal, ZAP, Chaves na Mão); 4 recusam, respeitados.
- 1.658 linhas em 196 s, robô identificado, 2 s entre páginas.
- 846 anúncios únicos após deduplicar por id.
- 594 residenciais com preço e área: a base do modelo.
- 16 colunas; o modelo usa 6: cidade, tipo, bairro, área, quartos, banheiros.
- Tabela Delta no Databricks; CSV no Azure Blob.

Fase 2. Análise: o que a base diz antes de qualquer modelo





Cauda à direita

média R$ 4.231 acima da mediana R$ 3.500. Um modelo que minimiza erro quadrático vai ser puxado pelos caros.

Bairro explica muito

Jardim Atlântico R$ 5.500, Conquista R$ 2.250. Bairro entra como variável, e entra como one-hot.

n pequeno por célula

Itabuna tem 52 anúncios. Qualquer bairro de Itabuna com 3 anúncios não sustenta um coeficiente.

Perguntas que esta base responde, e as que ela não responde

Responde (com SQL, Genie ou pandas)

- Qual a mediana do aluguel residencial por cidade e por bairro?
- Quanto custa o m² em Ilhéus e em Itabuna? (R$ 40,0 e R$ 18,6)
- Quais bairros têm mais oferta anunciada? (Nossa Senhora da Vitória, 193)
- Apartamento ou casa: qual é mais caro, controlando a área?
- Quanto um quarto a mais custa, em média, no mesmo bairro?
- Qual o imóvel de 2 quartos mais barato no Pontal hoje?
- Qual aluguel esperar para um imóvel com estas características? (o modelo)

Não responde (e por quê)

- Quanto custa alugar 'em Ilhéus'? Só o que está anunciado em 3 portais, numa data.
- O aluguel subiu? Só uma data. Repetir a coleta responde.
- Por quanto fecha o contrato? Preço anunciado não é preço pago.
- Quanto vale o condomínio, a mobília, o andar? Não estão na base.
- Qual bairro de Itabuna é mais caro? n = 52 na cidade; por bairro, não sustenta.
- O modelo serve para 2027? Só se for retreinado: o mercado muda, o modelo não.

Fase 3. Preparação: cinco tratamentos antes do modelo

Filtro

Só residencial, com preço e área: 846 → 594. Galpão de R$ 90.000 fora.

Bairros raros

Bairro com menos de 10 anúncios vira 'Outros': 11 categorias em vez de 60 com 2 anúncios cada.

Imputação

Quartos e banheiros vazios recebem a mediana do treino (SimpleImputer).

Treino e teste

80% para aprender, 20% guardados para avaliar. random_state = 42 para repetir.

Codificação e escala

Texto vira 0/1 (one-hot); número vira z-score (standard scaler). Aprendidos no treino, aplicados no teste.

```
res = df[df.residencial & (df.area_m2 > 0) & df.preco.notna()]
raros = res.bairro.value_counts() < 10
res["bairro_modelo"] =
res.bairro.where(~res.bairro.isin(raros.index[raros]), "Outros")

CATEG = ["cidade", "tipo", "bairro_modelo"]
NUMER = ["area_m2", "quartos", "banheiros"]
X, y = res[CATEG + NUMER], res["preco"]

X_tr, X_te, y_tr, y_te = train_test_split(X, y, test_size=0.2,
random_state=42)

prep = ColumnTransformer([
  ("cat", OneHotEncoder(handle_unknown="ignore"), CATEG),
  ("num", Pipeline([("imput", SimpleImputer(strategy="median")),
                    ("scale", StandardScaler())]), NUMER)])
```

Regra de ouro: tudo o que é 'aprendido' (mediana, média, desvio, categorias) é calculado só no treino. Se o teste entrar nessa conta, a avaliação mente.

Treino e teste: 475 para aprender, 119 para julgar



FIAP



Por que separar

Se avaliar no mesmo dado em que aprendeu, decorar vira 'acertar'. A árvore sem limite de profundidade acerta 100% do treino e erra no teste. O teste simula o anúncio de amanhã.

O que vai para cada lado

Sorteio aleatório, com semente fixa (random_state = 42) para o resultado repetir. 20% é convenção para bases pequenas; com 594 linhas, 119 no teste já dá uma métrica com ruído.

O que o teste não resolve

Não diz se o modelo serve para 2027, nem para outro portal, nem para Itabuna sozinha (10 anúncios no teste). Para escolher hiperparâmetros com rigor, validação cruzada (k-fold) no treino.

```
X_tr, X_te, y_tr, y_te = train_test_split(X, y, test_size=0.2, random_state=42)
# treino: 475 anúncios | teste: 119 anúncios (20%, nunca vistos no treino)
```

One-hot encoder: texto vira colunas de 0 e 1

Antes: uma coluna de texto

id	bairro_modelo
2902416120	Nossa Senhora Da Vitoria
2907651517	Sao Francisco
2919632298	Outros

›

Depois: uma coluna por categoria (11 bairros → 11 colunas)

id	N.S.Vitoria	Sao Francisco	Outros	…
2902416120	1	0	0	0
2907651517	0	1	0	0
2919632298	0	0	1	0

Por que

Regressão linear só multiplica números. 'Pontal' não multiplica. Cada bairro vira um interruptor 0/1 com o próprio coeficiente: Jardim Atlântico +R$ 1.119, Olivença −R$ 1.772 (nossa regressão).

Cuidado 1

Categoria nova no teste ou no dado novo: handle_unknown='ignore' põe zero em tudo (vira 'bairro médio'). Sem isso, o modelo quebra no primeiro bairro que não viu.

Cuidado 2

Categoria com 1 anúncio aprende ruído: tipo 'Accommodation' (1 flat) recebeu +R$ 827. Por isso bairros raros viraram 'Outros' antes.

```
OneHotEncoder(handle_unknown="ignore")   # 3 colunas de texto -> 1 + 3 + 11 = 15 colunas de 0/1
```

Standard scaler: desvios acima da média

z = (x − média) / desvio padrão

média e desvio calculados só no TREINO e reaplicados no teste e nos dados novos. Depois da escala, toda coluna numérica tem média 0 e desvio 1.

Exemplo com a nossa base (área, m²)

anúncio	area_m2	z	leitura
kitnet	35	≈ −0,8	abaixo da média
apto 2q	76	≈ −0,3	perto da média
casa	250	≈ +1,9	bem acima

valores aproximados: a média e o desvio exatos saem do treino (475 anúncios) e mudam a cada coleta.

Para que serve

Área vai de 20 a 400; quartos, de 1 a 5. Sem escala, a área domina qualquer método baseado em distância ou em regularização, e os coeficientes ficam incomparáveis. Com escala, 'um desvio de área' e 'um desvio de quartos' pesam na mesma unidade.

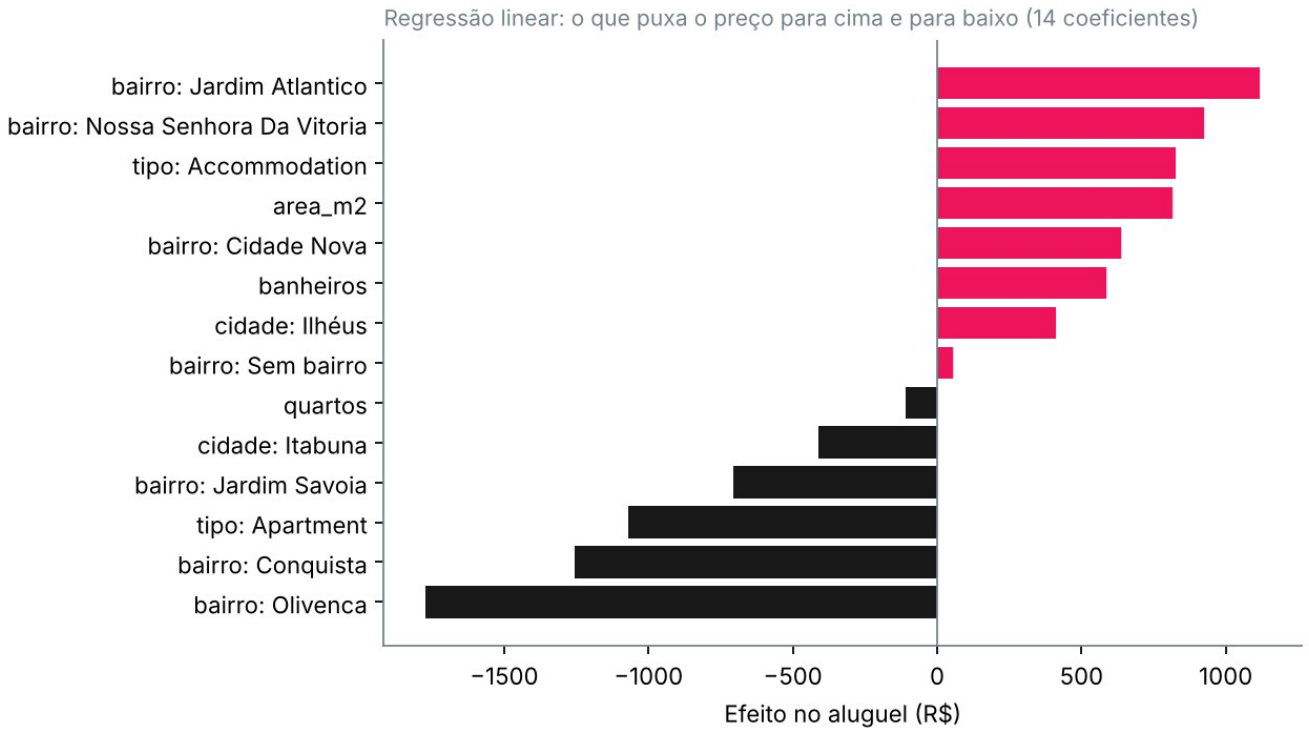
Quando não precisa

Árvore de decisão compara 'área ≤ 163 m²?': não liga para escala. Na nossa árvore usamos só imputação, sem scaler, e os cortes ficaram legíveis em m². O resultado é idêntico com ou sem escala.

O que muda na regressão

Com scaler, o coeficiente de área (+R$ 816) significa 'um desvio padrão de área a mais'. Sem scaler, significaria 'um m² a mais'. Os dois estão certos; a leitura muda.

Fase 4. Regressão linear: o preço como soma de efeitos



`aluguel ≈ b0 + b1·área + b2·quartos + … + bJA·[Jardim Atlântico] + …`

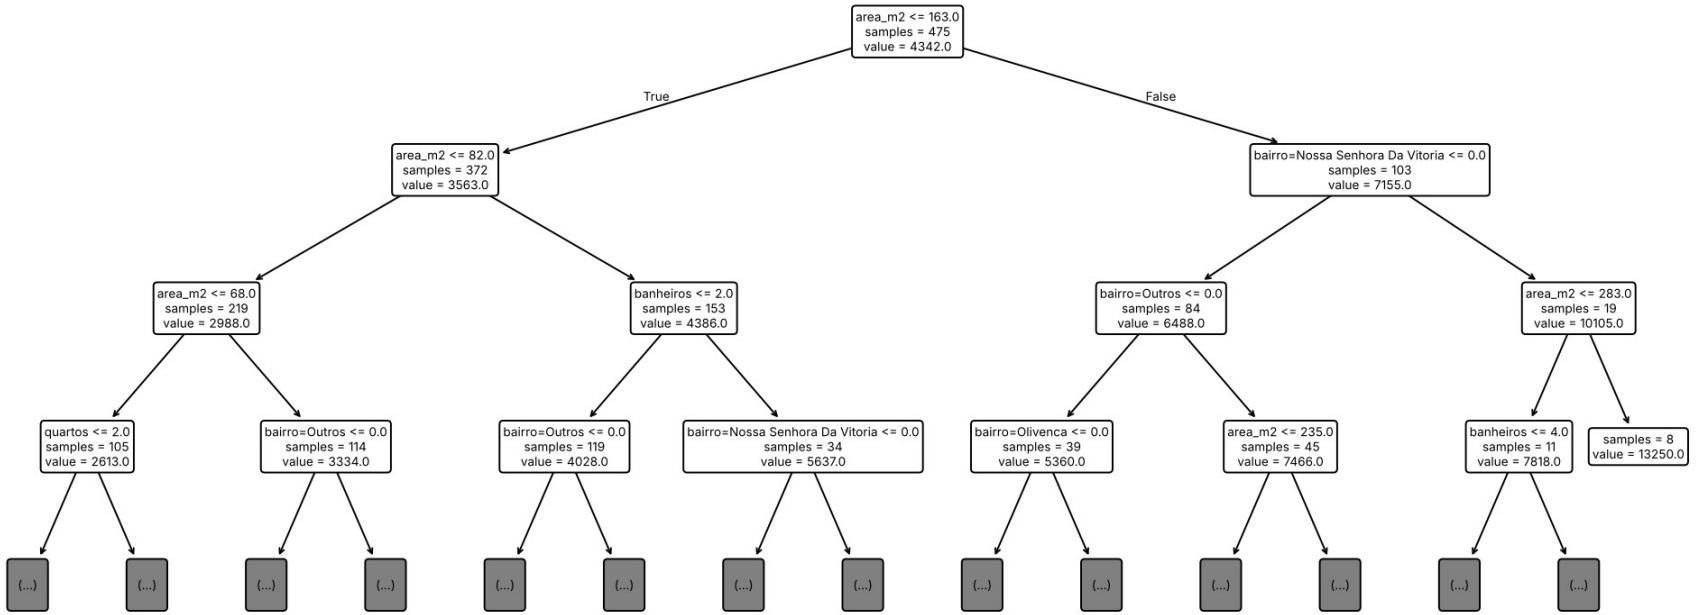
- Cada coeficiente é um efeito 'tudo o mais constante'. Jardim Atlântico: +R$ 1.119 em relação ao bairro de referência.
- Área: +R$ 816 por desvio padrão de área a mais.
- Quartos: −R$ 108. Negativo! Quartos e área andam juntos (colinearidade): com a área fixa, mais quartos significa quartos menores.
- Apartment: −R$ 1.069 em relação à casa, controlando área e bairro.

```
Pipeline([("prep", prep), ("modelo", LinearRegression())]).fit(X_tr, y_tr)
```

Interpretável, rápido, e assume que os efeitos somam. Não captura 'área vale mais no Jardim Atlântico que em Conquista' sem termos de interação.

Árvore de decisão: o preço como sequência de perguntas

Árvore de decisão: os três primeiros níveis (area em m², value = aluguel médio em R$; a árvore completa tem profundidade 5)



Como ler

Primeira pergunta: área ≤ 163 m²? Sim: 372 anúncios, média R$ 3.563. Não: 103, média R$ 7.155. Depois, bairro e banheiros. Cada folha é um grupo de anúncios parecidos; a previsão é a média da folha.

Freios: profundidade 5 e no mínimo 5 anúncios por folha. Sem eles, cada anúncio vira uma folha e o modelo decora.

```
DecisionTreeRegressor(max_depth=5, min_samples_leaf=5, random_state=42)   # sem StandardScaler: a árvore não precisa
```

A árvore descobriu sozinha o que a descritiva mostrou: área primeiro, bairro depois. Mesmas métricas com ou sem escala.

Fase 5. Métricas: vencem a base, nenhum é bom

MAE — **erro absoluto médio**

média de |real − previsto|. Em R$. Lê-se direto: 'erro típico de R$ 1.242'.

RMSE — **raiz do erro quadrático médio**

penaliza erros grandes. Se RMSE ≫ MAE, há poucos erros enormes (os caros).

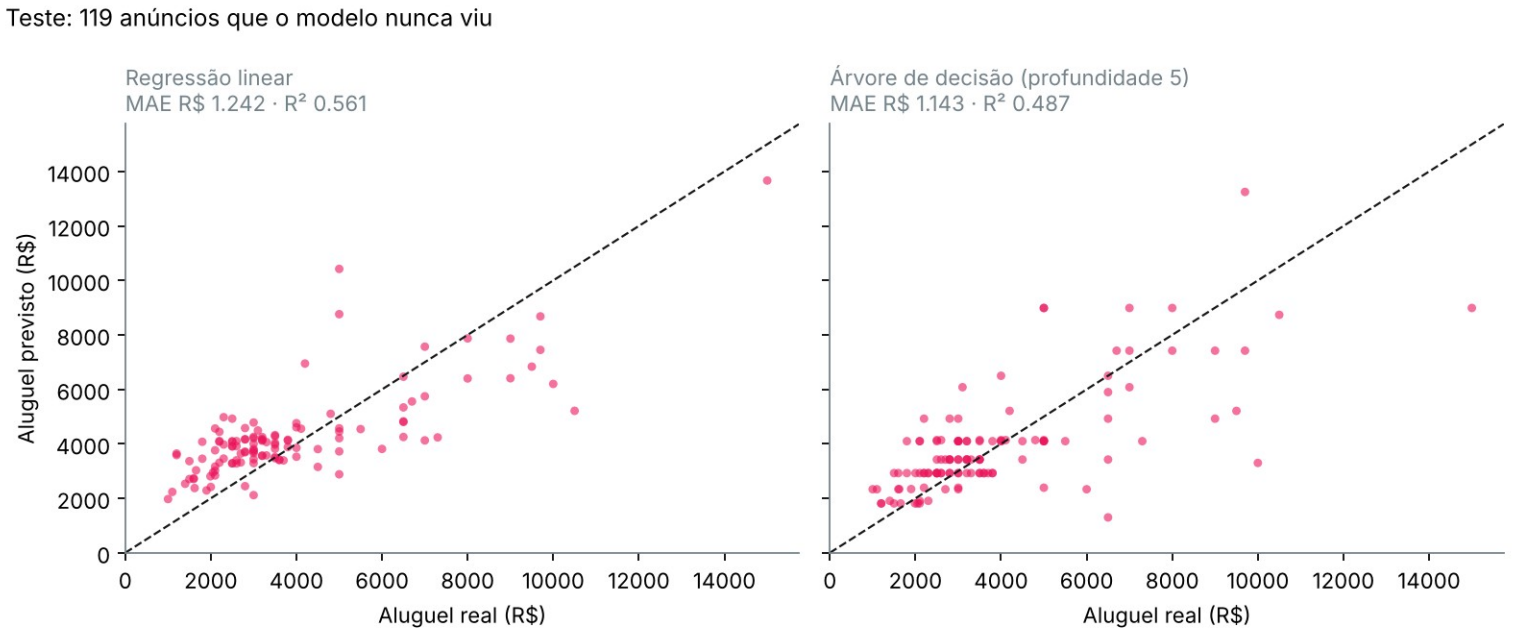
R^2 — **variância explicada**

0 = tão bom quanto prever a média; 1 = perfeito. Negativo = pior que a média.

Modelo	MAE (R$)	RMSE (R$)	R^2
Linha de base: prever sempre a mediana do treino	1.611	2.388	−0,03
Regressão linear	**1.242**	**1.562**	**0,56**
Árvore de decisão (profundidade 5, 5 por folha)	**1.143**	**1.688**	**0,49**

- A árvore tem MAE menor (erra menos no típico); a linear tem RMSE menor e R^2 maior (erra menos nos caros). Qual é 'melhor' depende da pergunta da fase 1.
- Erro típico de R$ 1.100 a 1.200 num aluguel mediano de R$ 3.500: cerca de 35%. Para o inquilino, não serve. Para ordenar bairros e tipos, serve.
- Por que não é melhor: 594 linhas, 6 variáveis, sem condomínio, mobília, andar, estado. O modelo reflete a base, e a base é o que o portal entrega.

Olhar o erro: real contra previsto nos 119 do teste



O que o gráfico conta

- Até R$ 4.000, os dois modelos acompanham a diagonal: é onde há dados.
- Acima de R$ 6.000, a linear subestima e a árvore chuta a média da folha (as 'linhas horizontais').
- O ponto de R$ 15.000 real: um anúncio que nenhum modelo tinha como prever com 6 variáveis.
- A árvore erra menos no comum e mais nos raros; a linear, o contrário.

Diagnóstico, não só nota

- Os resíduos grandes são uma lista de anúncios para abrir um a um: erro de digitação, imóvel de luxo, área errada, ou uma variável que falta.
- Próximo passo natural: prever log(preço) para a cauda pesar menos, e adicionar condomínio e 'mobiliado' na coleta (os portais publicam).
- Depois, validação cruzada para escolher a profundidade da árvore sem olhar o teste.

Fase 6. Previsão para anúncios novos, em uma linha

cidade	tipo	bairro	m²	q	b	Linear	Árvore
Ilhéus	Apartamento	N. S. da Vitória	70	2	2	R$ 4.134	R$ 3.424
Ilhéus	Casa	Pontal	150	3	2	R$ 5.115	R$ 4.099
Ilhéus	Apartamento	Jardim Atlântico	90	3	2	R$ 4.345	R$ 6.080
Itabuna	Apartamento	Outros	60	2	1	R$ 2.002	R$ 2.926

```
novo = pd.DataFrame([{"cidade": "Ilhéus", "tipo": "Apartment", "bairro_modelo":
"Pontal",
                      "area_m2": 70, "quartos": 2, "banheiros": 2}])
modelo.predict(novo)        # o mesmo pipeline: imputa, codifica, escala e prevê
# o que o modelo nunca viu (bairro novo) entra como zeros no one-hot: vira "bairro
médio"
```

Os modelos discordam em até R$ 1.700 no mesmo imóvel (Jardim Atlântico). Isso não é defeito: é a incerteza que a métrica escondia numa média.

O que 'implantar' significa aqui

- Guardar o pipeline treinado (joblib) e a data da coleta que o treinou; prever com um intervalo, não um número.
- No Databricks: o mesmo código num notebook sobre workspace.default.anuncios; MLflow registra modelo, métricas e versão (não executado nesta oficina).
- Retreinar a cada coleta: o desafio de casa (coletar de novo em uma semana) é também o ciclo de vida do modelo.

Para discutir e para fazer: o ciclo volta ao negócio

Perguntas

- MAE diz 'árvore', R^2 diz 'linear'. Qual você entregaria para a imobiliária? E para o inquilino?
- Erro de 35%: o modelo serve ou não serve? Serve para quê?
- Quartos com coeficiente negativo: você tira a variável, explica, ou troca por 'm^2 por quarto'?
- O modelo foi treinado em anúncios de 06/11. Vale em dezembro? Como você saberia?
- Se o Genie respondesse 'qual o aluguel esperado de um apto de 70 m^2 no Pontal', de onde viria o número?

Próximos passos, em ordem de custo

- 1. Prever log(preço): 2 linhas de código, cauda pesa menos.
- 2. Validação cruzada (k = 5) no treino para escolher a profundidade da árvore.
- 3. Voltar à coleta: condomínio e 'mobiliado' estão no ld+json (additionalProperty); 'vagas' também.
- 4. Interações: área × bairro, ou um modelo de floresta aleatória.
- 5. Série temporal: repetir a coleta semanalmente e acompanhar a mediana e o erro do modelo.
- 6. Databricks: registrar o modelo no MLflow e servir a previsão como função SQL.

Fontes, código e o que não verifiquei

Fontes e datas

- Base: anuncios_limpo.csv, coleta de 06/11/2026 (VivaReal, ZAP, Chaves na Mão). Modelo: ml/modelo_aluguel.py, executado em 07/11/2026, 8h50; scikit-learn 1.9.1.
- Salários: Portal Salário / CAGED (cientista CBO 2031-05 e estatístico-analista CBO 2112-05, 06/2025 a 05/2026; engenheiro CBO 2122-05, 05/11/2026); Numerando / Novo CAGED (ref. 01 e 03/2026); Glassdoor via Data Hackers (2.717 salários); DataHire Club (vagas públicas, 2026).
- CRISP-DM: Chapman et al., 'CRISP-DM 1.0 Step-by-step data mining guide', 2000.
- Métricas e pré-processamento: documentação do scikit-learn (train_test_split, OneHotEncoder, StandardScaler, LinearRegression, DecisionTreeRegressor).
- Foto da capa: turismobahia, CC BY-SA 2.0, Wikimedia Commons.

O que não verifiquei

- O número do analista de dados no Glassdoor (exige login): citado de segunda mão e marcado assim.
- Validação cruzada e log(preço): sugeridos, não executados.
- MLflow e função SQL no Databricks: mencionados, não executados.
- Os valores de z no exemplo do scaler são aproximados; os exatos saem do treino.
- Estabilidade das métricas: um único sorteio treino/teste (random_state 42). Outro sorteio dá outro MAE; a diferença entre os modelos pode trocar de sinal.

```
Repositório: pasta ml/ (modelo_aluguel.py, metricas.json,
previsoes_novos.csv, 3 gráficos). Roda com: cd ml && python
modelo_aluguel.py
```